

新用户次月活跃预测：实验报告

2026-10-06

摘要。 本报告整理了截至目前的四项改进。

- 1. 定位并修复了标签污染问题：一条名为 badge_OCZE 的记录让 M12 注册用户的"次月活跃率"从约 29% 被抬高到 78%。
- 2. 用类别加权缓解了 1:4 的正负样本不平衡。
- 3. 用超参数搜索解决了决策树的过拟合。
- 4. 把具体页面列改为按页面类别计数，让特征能推广到新的月份。

在修复后的数据上，表现最好的两个模型是加权逻辑回归（F1 = 0.475）和调参后、按类别构造特征的决策树（F1 = 0.469）。两者都明显超过了 all-ones 基线（0.328）。

1. 背景与实验设置

任务。 Zindi「新用户次月活跃预测」：根据新用户注册当月的行为，预测他在注册后的下一个月是否活跃。官方指标是正类（Active = 1）的 F1，提交的是 0/1 硬标签。

数据。 共 12,413 个用户。注册月份经过脱敏，按时间先后依次为 11 → 12 → 1 → 2 → 3 → 4 → 5。下文用 M11、M12 等表示"在该月注册的用户"。需要提交预测的是 M4 注册的 1,340 个用户。

标签 Y。 用户在注册后的下一个月，只要在点击日志、比赛报名、发帖、评论四张表中有任何一条记录，就记为 1，否则记为 0。M4 的标签被比赛方隐藏；M5 没有下一个月的数据，因此没有标签。所以有标签的是 M11-M3 注册的 9,026 个用户。

特征 X。 只使用注册当月的事件，包括两部分：

- Users.csv 中的 5 列画像：FeatureX、FeatureY、国家、注册日、注册小时；
- 每种行为为一列，值是该行为在注册当月发生的次数。比赛页、博客页这类具体页面，每个页面编号单独占一列。

评估方式。

项目	设置
内部评估	有标签用户按用户随机切成 5 折（按标签分层，seed = 42），所有模型使用同一套切分，报告 F1 的均值 ± 标准差
外部评估	官方 leaderboard，在 M4 用户上计算
判定阈值	模型输出的概率 ≥ 0.5 时判为 1，所有实验都不调阈值

全部预测为 1（all-ones）时，召回率等于 1，精确率等于正样本比例 p，所以 F1 只由 p 决定：

$$F1(\text{all-ones}) = 2p / (1 + p)$$
, 反过来 $p = F1 / (2 - F1)$

利用这个关系，可以从 all-ones 的分数反推出数据中的正样本比例。第 2 节就是用它来发现问题的。

2. 起点：内部评估和 leaderboard 不一致

最初的设置使用原始数据，没有任何处理。结果如下：

模型	5 折交叉验证 F1	leaderboard F1
all-ones	0.468	0.25
逻辑回归	0.677 ± 0.019	低于 all-ones

这里有两个异常：

1. **all-ones 的分数从 0.468 掉到了 0.25。**按上面的公式反推，有标签数据的正样本比例是 0.305，而测试集只有约 0.143，相差一倍多。all-ones 不依赖任何特征，所以这个差距只能来自**标签的分布**本身。
2. **逻辑回归在交叉验证中远好于 all-ones，在 leaderboard 上却更差。**它只把 1,340 个测试用户中的 47 人（3.5%）预测为活跃，而测试集真实的活跃比例约为 14%。

由此提出后面几节要检验的假设：

编号	假设	对应的现象
H1	训练标签中有一部分被异常抬高了	异常 1
H2	正负样本不平衡，加上 0.5 的阈值，让模型过于保守	异常 2
H3	不限深度的决策树会过拟合	换成树模型后的新问题
H4	按页面编号构造的特征无法推广到新的月份	测试月出现了新比赛、新博客

3. H1：M12 的标签被 badge_OCZE 污染

3.1 先定位到哪个月

把有标签的数据按注册月拆开，看每个月的"次月活跃率"：




图 1：各注册月的次月活跃率。灰色是原始标签，蓝色是去掉 `badge_OCZE` 之后的标签。橙色虚线是从 leaderboard 反推出的测试集活跃率。

解读。看灰色柱子：M11、M1、M2、M3 都在 12%–21% 之间，测试集的约 14% 也落在这个范围内，只有 **M12 高达 78%**。因此第 2 节中整体正样本比例偏高（0.305），主要来自 M12 这一个月。

3.2 再定位到哪种行为

M12 用户的"下一个月"是 M1。我们统计了在 M1 被判为活跃的 M12 用户各做了哪些事，并与其他月份的活跃用户做对比：




图 2：上图是“下个月活跃”的用户中，在标签月做过每种行为的比例（蓝色为 M12，橙色为其他月份）。下图是 M12 全部 1,982 个用户按标签月的行为拆分。

解读。

- 只有 `badge_OCZE` 一项明显异常：M12 的活跃用户中有 **96%** 有这条记录，其他月份只有 **5%**。
- 真实的使用行为（浏览比赛、浏览讨论、下载数据、提交、登录），M12 反而都只有其他月份的一半左右。
- 下图显示，M12 中有 **987 人（50%）** 在下一个月只有这一条记录，没有任何其他行为。
- 这条记录集中出现在 M1 的第 15 天，当天有 3,005 个用户同时获得。这种分布不像用户的主动行为，更像系统批量发放的徽章（这一点是推断，官方没有说明）。

3.3 修复与验证

修复。 在读取数据时，直接删除 `UserActivity.csv` 中 `Title = badge_OCZE` 的 8,864 行。这样 X 和 Y 都不再受它影响。

验证。 如果 H1 成立，删除这条记录后，M12 应该回到正常水平，而其他月份不受影响。

指标	修复前	修复后
M12 次月活跃率	78.4%	28.6%
其他月份次月活跃率	12%–21%	不变
整体正样本比例	0.305	0.196
all-ones 交叉验证 F1	0.468	0.328
逻辑回归交叉验证 F1	0.677	0.375

结论。 H1 成立。M12 回到了和其他月份相近的水平（图 1 中的蓝色柱子）。all-ones 的交叉验证分数也向 leaderboard 的 0.25 靠近了。

逻辑回归从 0.677 降到 0.375，说明之前的高分有很大一部分来自"认出 M12 用户"，而不是真正学到了用户行为。**之后所有实验都在修复后的数据上进行。**

4. H2：正负样本 1:4，让模型预测"活跃"太少

现象。 修复后，正样本有 1,770 个，占 19.6%，正负比约为 1:4。逻辑回归在测试集上给出的平均概率只有约 0.12，能超过 0.5 的人很少：它只把 51 人（3.8%）预测为活跃，而真实比例约为 14%。

F1 对漏掉正样本的惩罚很重。比如测试集真有约 190 个活跃用户时，即使这 51 个预测全部正确，召回率也只有约 27%。

实验。 只改一处：给逻辑回归设置 `class_weight="balanced"`。训练时每个正样本的权重约为负样本的 4 倍。阈值仍然是 0.5，其余设置全部不变。

模型	交叉验证 F1	测试集预测为活跃的人数
逻辑回归	0.375 ± 0.027	51 (3.8%)
逻辑回归 + 类别加权	0.475 ± 0.011	137 (10.2%)

结论。 H2 成立。加权之后，模型敢于预测更多人活跃，预测比例从 3.8% 提高到 10.2%，更接近真实的约 14%。F1 提高了 0.10，远大于各折之间的波动（标准差约 0.01–0.03）。

5. H3：默认决策树严重过拟合

现象。 sklearn 默认的决策树不限制深度。每一折训练出来的树深度达到 46–63 层，约有 1,400 片叶子，训练集 F1 是 0.995，验证集 F1 只有 0.391。

实验。 在 216 组超参数上做网格搜索，用内层 5 折交叉验证的 F1 选出最优组合：

超参数	候选值
max_depth	2, 3, 4, 5, 6, 8, 10, 15, 不限
min_samples_leaf	1, 5, 10, 20, 50, 100
criterion	gini, entropy
class_weight	None, balanced

为了不让选参数这一步高估结果，采用**嵌套交叉验证**：外层 5 折中的每一折，都只用这一折的训练数据来搜索参数，然后在验证集上评估。

模型	深度	叶子数	训练集 F1	验证集 F1
默认决策树	46-63	约 1,400	0.995	0.391 ± 0.014
调参后的决策树	8	约 151	0.553	0.456 ± 0.019

在全部有标签数据上搜索得到的最优参数是：max_depth = 8, min_samples_leaf = 5, criterion = gini, class_weight = balanced。

结论。 H3 成立。限制深度后，训练集和验证集的差距从约 0.60 缩小到约 0.10，验证集 F1 提高了 0.065。搜索自动选择了 class_weight = balanced，这与 H2 的结论一致。

6. H4：按页面编号构造的特征无法推广到新月份

现象。 比赛和博客每个月都在更新。按页面编号构造特征时，测试用户访问的新页面在训练数据中对应的列全是 0，模型从中学不到任何东西。




图 3：测试集（M4）的每一次页面浏览，按“它落入的那一列在训练数据中有多少用户”着色。橙色表示训练中从未出现。前三行是按页面编号构造的列，最后一行是按类别构造的列。

解读。

- 按页面编号构造时，测试集中 **29%** 的比赛浏览、**23%** 的博客浏览、**53%** 的职位浏览落在训练从未出现过的列上，还有相当一部分落在只有不到 50 个训练样本的列上。
- 主要原因是 M4 最热门的比赛 comp_ID_WZ0H 是新比赛，在训练数据中一次都没有出现过。
- 这并不是 M4 特有的现象。在其他月份，比赛浏览中落在新比赛上的比例也有 31%–64%，最热门的比赛几乎每一两个月就换一次 (WOVD → 528W → GAV9 → WZ0H → IMTG)。
- 按类别构造时 (comp_page、blog_page、job_page、badge 各一列)，同样的 2,669 次浏览 **100%** 落在训练样本充足的列上。

实验。 只改变 X 的构造方式：具体页面按类别合并计数，X 从 390 列变为 45 列，每个用户的行为总次数不变。超参数搜索空间、嵌套交叉验证、数据切分都与第 5 节完全相同。

决策树（调参后）	特征数	交叉验证 F1	最优参数	测试集预测为活跃
按页面编号	390	0.456 ± 0.019	深度 8，叶子最少 5 个样本	246 (18.4%)
按类别	45	0.469 ± 0.011	深度 5，叶子最少 1 个样本	233 (17.4%)

结论。 部分成立。

- 按类别构造后，F1 提高了 0.013，标准差也更小 (0.019 → 0.011)，最优树更浅 (深度 8 → 5)，说明模型更简单、更稳定。
- 不过 0.013 的提升与各折之间的波动处在同一量级。
- 内部评估采用的是随机切分，训练集和验证集来自同样的几个月，"新页面"的问题在内部评估中会被低估。按类别构造的真正收益，应该在 leaderboard 或按时间切分的评估中体现得更明显 (见第 8 节)。

7. 结果汇总




图 4：各模型在修复后数据上的 5 折交叉验证 F1（均值 ± 标准差）。蓝色是加入改进后的模型，橙色虚线是 all-ones 基线。

改进	对比	F1 变化	依据
H1 去掉 badge_OCZE	修复前 → 修复后	不可直接比较（标签变了）	图 1、图 2；M12 活跃率 78% → 29%
H2 类别加权	逻辑回归 → 加权逻辑回归	0.375 → 0.475	第 4 节
H3 超参数搜索	默认决策树 → 调参后的决策树	0.391 → 0.456	第 5 节
H4 按类别构造 X	调参后的决策树：按页面 → 按类别	0.456 → 0.469	图 3，第 6 节

总结论。

1. 本项目最大的问题出在**标签**，而不是模型。一条系统写入的徽章记录污染了一整个月的标签，让内部评估严重偏乐观。这个问题是通过 all-ones 在内部评估和 leaderboard 上的分数差距发现的。
2. 在干净的标签上，**类别加权**和**控制模型复杂度**是两项最有效的改进，分别让 F1 提高了约 0.10 和 0.065。
3. 按类别构造特征的思路有数据支撑（图 3），但在随机切分的评估下，收益暂时只有 0.013。

8. 局限与说明

- **随机切分会混合月份。** 同一个月的用户可能同时出现在训练集和验证集中，因此"新页面""月份分布漂移"这类问题在内部评估中会被低估。按时间切分（用过去的月份预测下一个月）会更接近真实的使用场景。

- **阈值固定为 0.5。** 为了让各项实验可以直接对比，所有实验都没有调整阈值。F1 对阈值很敏感，阈值本身也是一个独立的优化方向。
- **leaderboard 结果不完整。** 目前只确认了修复前的 all-ones (0.25) 和逻辑回归 (低于 all-ones) 的成绩。修复后各模型的 leaderboard 成绩还有待提交验证，对应的提交文件已经在 `outputs/` 中生成。
- **推断未被证实。** "badge_OCZE 是系统批量发放的徽章"是根据数据分布做出的推断，官方没有说明，官方也没有给出"活跃"的定义。
- **测试集正样本比例是估算值。** 约 14% 是从 all-ones 的 leaderboard 分数反推出来的。如果 leaderboard 只用了部分测试用户计算，这个估计会有误差。

附录：复现

内容	命令	输出
交叉验证	<code>python3 scripts/run_cv.py</code>	<code>outputs/cv_scores.csv</code>
提交文件	<code>python3 scripts/make_submissions.py</code>	<code>outputs/submission_*.csv</code> 、 <code>outputs/tree_search*.csv</code>
图 1、图 4	<code>python3 scripts/report_figures.py</code>	<code>outputs/cohort_positive_rate.png</code> 、 <code>outputs/cv_f1_summary.png</code>
图 2	<code>python3 scripts/plot_m12_label.py</code>	<code>outputs/m12_label_activity.png</code>
图 3	<code>python3 scripts/page_novelty.py</code>	<code>outputs/page_support.png</code>
渲染 PDF	<code>python3 scripts/render_report.py</code> (需要安装 <code>markdown</code> 、 <code>weasyprint</code>)	<code>report/report.pdf</code>

主要的提交文件：

文件	模型
<code>submission_logreg_per_page_balanced_no_badge.csv</code>	加权逻辑回归
<code>submission_decision_tree_tuned_no_badge.csv</code>	调参后的决策树 (按页面编号)
<code>submission_decision_tree_tuned_no_badge_by_type.csv</code>	调参后的决策树 (按类别)